

Часть 4. Обработка текста.

Влад 'mend0za' Шахов
Linux & Embedded Team Leader

Linux & Embedded Department



Введение в Unix-Way

Заповедь номер 3:

Всё есть текст¹

¹см статью Дениса Смирнова 'Классический Unix-way'



Введение в Unix-Way

Заповедь номер 3:

Всё есть текст¹

Заповедь номер 4:

Пускайте данные по трубам

¹см статью Дениса Смирнова 'Классический Unix-way'



Введение в Unix-Way

Заповедь номер 3:

Всё есть текст¹

Заповедь номер 4:

Пускайте данные по трубам

Заповедь номер 5:

Всё есть файл

¹см статью Дениса Смирнова 'Классический Unix-way'



Текст в Unix-Way

В Unix (и Linux) в виде обычного текста или **plain text** представлены:

² в каталоге \$HOME

³ в каталоге /etc

⁴ справедливо для **syslog** и совместимых систем

⁵ 'Unix is toolbox' - 'Unix это ящик с инструментами'



Текст в Unix-Way

В Unix (и Linux) в виде обычного текста или **plain text** представлены:

- **конфигурационные файлы**, как локальные², так и общесистемные³

² в каталоге \$HOME

³ в каталоге /etc

⁴ справедливо для **syslog** и совместимых систем

⁵ 'Unix is toolbox' - 'Unix это ящик с инструментами'



Текст в Unix-Way

В Unix (и Linux) в виде обычного текста или **plain text** представлены:

- **конфигурационные файлы**, как локальные², так и общесистемные³
- **системные логи**⁴
- **исходные тексты программ**, включая скрипты на Shell
- **основной формат ввода и (или) вывода данных** для множества программ и утилит

²в каталоге \$HOME

³в каталоге /etc

⁴справедливо для **syslog** и совместимых систем

⁵'Unix is toolbox' - 'Unix это ящик с инструментами'



Текст в Unix-Way

В Unix (и Linux) в виде обычного текста или **plain text** представлены:

- **конфигурационные файлы**, как локальные², так и общесистемные³
- **системные логи**⁴
- **исходные тексты программ**, включая скрипты на Shell
- **основной формат ввода и (или) вывода данных** для множества программ и утилит

Богатый выбор изодранных острогаченных инструментов для работы с текстом во всех представлениях⁵

²в каталоге \$HOME

³в каталоге /etc

⁴справедливо для **syslog** и совместимых систем

⁵'Unix is toolbox' - 'Unix это ящик с инструментами'



Просмотр обычных файлов

- Просмотр текста:
 - `cat` - вывести на stdout⁶

⁶ Для двоичных файлов: чревато порчей настроек терминала
⁷ может отсутствовать в стандартной поставке



Просмотр обычных файлов

- Просмотр текста:
 - **cat** - вывести на stdout⁶
 - **more** - вывести, разбив на страницы
 - **less**⁷ - **more** на стероидах, с прокруткой, поиском

⁶ Для двоичных файлов: чревато порчей настроек терминала
⁷ может отсутствовать в стандартной поставке



Просмотр обычных файлов

- Просмотр текста:
 - **cat** - вывести на stdout⁶
 - **more** - вывести, разбив на страницы
 - **less**⁷ - **more** на стероидах, с прокруткой, поиском
- Просмотр двоичных данных:
 - **od** - дамп файла в не-текстовых форматах

```
~$ od -c .bashrc
0000000  #      ~   /   .   b   a   s   h   r   c   :   e   x   e
0000020  c   u   t   e   d   b   y   b   a   s   h   (   1   )

~$ od -x .bashrc
0000000  2023 2f7e 622e 7361 7268 3a63 6520 6578
0000020  7563 6574 2064 7962 6220 7361 2868 2931

~$ od -f .bashrc
0000000  2.311258e-10  1.785672e+31  8.676411e-04  7.331327e+22
0000020  7.215143e+22  7.338225e+34  1.785670e+31  3.933694e-14
```

- **strings** - извлечь текстовые строки из двоичных файлов

⁶ Для двоичных файлов: чревато порчей настроек терминала
⁷ может отсутствовать в стандартной поставке



Редакторы

- Любой редактор, с которым вы можете справиться.

⁸В этом качестве он внесен в стандарт Single Unix Specification. Существует множество реализаций редакторов, совместимых с vi: vim, elvis, nvi, vi-mode в Emacs, Sublime Text 2, vi из busybox и т.д.

⁹С получением и сохранением данных по протоколу FTP и SSH



Редакторы

- Любой редактор, с которым вы можете справиться. Но его может не быть в вашей системе...

⁸В этом качестве он внесен в стандарт Single Unix Specification. Существует множество реализаций редакторов, совместимых с vi: vim, elvis, nvi, vi-mode в Emacs, Sublime Text 2, vi из busybox и т.д.

⁹С получением и сохранением данных по протоколу FTP и SSH



Редакторы

- Любой редактор, с которым вы можете справиться. Но его может не быть в вашей системе...
- Редактор **vi** присутствует как стандартный в любой Unix-подобной системе⁸

⁸В этом качестве он внесен в стандарт Single Unix Specification. Существует множество реализаций редакторов, совместимых с vi: vim, elvis, nvi, vi-mode в Emacs, Sublime Text 2, vi из busybox и т.д.

⁹С получением и сохранением данных по протоколу FTP и SSH



Редакторы

- Любой редактор, с которым вы можете справиться. Но его может не быть в вашей системе...
- Редактор **vi** присутствует как стандартный в любой Unix-подобной системе⁸
- Не обязательно редактировать локально: В **mc**, **vim**, **emacs** есть возможность удалённого редактирования файлов⁹.

⁸В этом качестве он внесен в стандарт Single Unix Specification. Существует множество реализаций редакторов, совместимых с vi: vim, elv, nvi, vi-mode в Emacs, Sublime Text 2, vi из busybox и т.д.

⁹С получением и сохранением данных по протоколу FTP и SSH



vi и vim

Перед стартом:

- 1 Редактор vi изначально создавался как универсальный и переносимый¹⁰. Все действия можно осуществить на алфавитно-цифровой части клавиатуры, без мыши.

¹⁰Обязан работать на любых типах терминалов и виртуальных консолей

¹¹Командного стиля, а не меню-ориентированный

¹²сохранение, открытие файлов, выход, вставка файла в текущий и т.д.

¹³`export LANG='ru_RU.UTF-8'` - на русском языке



vi и vim

Перед стартом:

- 1 Редактор vi изначально создавался как универсальный и переносимый¹⁰. Все действия можно осуществить на алфавитно-цифровой части клавиатуры, без мыши.
- 2 Редактор командного стиля¹¹. Действия подачей прямых управляющих команд.

¹⁰Обязан работать на любых типах терминалов и виртуальных консолей

¹¹Командного стиля, а не меню-ориентированный

¹²сохранение, открытие файлов, выход, вставка файла в текущий и т.д.

¹³`export LANG='ru_RU.UTF-8'` - на русском языке



vi и vim

Перед стартом:

- 1 Редактор vi изначально создавался как универсальный и переносимый¹⁰. Все действия можно осуществить на алфавитно-цифровой части клавиатуры, без мыши.
- 2 Редактор командного стиля¹¹. Действия подачей прямых управляющих команд.

3 основных режима: ~~портить текст и противно библиковать~~

- Командный режим (Normal mode) - по умолчанию при запуске.
- Режим изменения текста (Edit mode)
- Режим построчного редактирования (Ex mode) - операции над файлом целиком¹².

¹⁰Обязан работать на любых типах терминалов и виртуальных консолей

¹¹Командного стиля, а не меню-ориентированный

¹²сохранение, открытие файлов, выход, вставка файла в текущий и т.д.

¹³export LANG='ru_RU.UTF-8' - на русском языке



vi и vim

Перед стартом:

- 1 Редактор vi изначально создавался как универсальный и переносимый¹⁰. Все действия можно осуществить на алфавитно-цифровой части клавиатуры, без мыши.
- 2 Редактор командного стиля¹¹. Действия подачей прямых управляющих команд.

3 основных режима: ~~портить текст и противно библиковать~~

- Командный режим (Normal mode) - по умолчанию при запуске.
- Режим изменения текста (Edit mode)
- Режим построчного редактирования (Ex mode) - операции над файлом целиком¹².

Упражнение: проходим **vimtutor**, встроенный в vim учебник¹³

¹⁰ Обязан работать на любых типах терминалов и виртуальных консолей

¹¹ Командного стиля, а не меню-ориентированный

¹² сохранение, открытие файлов, выход, вставка файла в текущий и т.д.

¹³ export LANG='ru_RU.UTF-8' - на русском языке



Текстовый фильтр

Определение:

Текстовый фильтр - программа, обрабатывающая и преобразующая текст.

Примеры: **sort**, **cat**, **tac**, **rev**



Текстовый фильтр

Определение:

Текстовый фильтр - программа, обрабатывающая и преобразующая текст.

Примеры: **sort**, **cat**, **tac**, **rev**

- Фильтр, запущенный без параметров - читает стандартный ввод.
- Параметры фильтра - интерпретируются как имена файлов
- Ключи фильтра - управляют режимами работы



Текстовый фильтр

Определение:

Текстовый фильтр - программа, обрабатывающая и преобразующая текст.

Примеры: **sort**, **cat**, **tac**, **rev**

- Фильтр, запущенный без параметров - читает стандартный ввод.
- Параметры фильтра - интерпретируются как имена файлов
- Ключи фильтра - управляют режимами работы

Фильтр почти всегда используется совместно с перенаправлением ввода-вывода Shell (особенно '|', pipes).



Простые текстовые фильтры

Соглашения о параметрах: `!` как имя файла обозначает стандартный ввод.

- `cat` и `tac` - вывести файл целиком



Простые текстовые фильтры

Соглашения о параметрах: **'-'** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла



Простые текстовые фильтры

Соглашения о параметрах: **!** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла
- **sort** и **uniq** - сортировка и убрать повторы в отсортированном



Простые текстовые фильтры

Соглашения о параметрах: **!** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла
- **sort** и **uniq** - сортировка и убрать повторы в отсортированном
- **grep** - поиск по образцу



Простые текстовые фильтры

Соглашения о параметрах: **!** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла
- **sort** и **uniq** - сортировка и убрать повторы в отсортированном
- **grep** - поиск по образцу
- **paste** - объединить файлы построчно



Простые текстовые фильтры

Соглашения о параметрах: **'-'** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла
- **sort** и **uniq** - сортировка и убрать повторы в отсортированном
- **grep** - поиск по образцу
- **paste** - объединить файлы построчно
- **wc** - счётчик строк, слов и байт в тексте



Простые текстовые фильтры

Соглашения о параметрах: **!-** как имя файла обозначает стандартный ввод.

- **cat** и **tac** - вывести файл целиком
- **head** и **tail** - вывести начало и конец файла
- **sort** и **uniq** - сортировка и убрать повторы в отсортированном
- **grep** - поиск по образцу
- **paste** - объединить файлы построчно
- **wc** - счётчик строк, слов и байт в тексте
- **tee** - копирует стандартный ввод в файл и на экран



Простые фильтры - упражнения

Упражнение 1: посчитать сколько файлов в папке `/bin`¹⁴

Упражнение 2: сколько слов в первых 15 строках `.bashrc`¹⁵

Упражнение 3: найти, в каких файлах (и сколько их вообще) в области системных логов (каталог `/var/log`) была записана информация о входе вашего пользователя в систему.¹⁶

Упражнение 4: сколько было входов в систему от имени вашего пользователя? в какое время был первый? последний?¹⁷

Упражнение 5: то же, что и 4. Только для выходов.
Дополнительно сохранить записи о ваших выходах в отдельный файл.¹⁸

¹⁴ подсказка - `wc` и `ls`

¹⁵ подсказка - `head` и `ls`

¹⁶ подсказка - `grep` и, возможно, но необязательно, `uniq`

¹⁷ подсказка - `grep`, `head`, `tail`

¹⁸ подсказка: + `tee`



Изощёренные фильтры

- **diff** (и **diff -u**¹⁹) - сравнить 2 файла и получить описание разницы (изменения между ними)
- **patch** - утилита применения изменений от diff

¹⁹Формат **diff -u** : индустриальный стандарт пересылки списка изменений между версиями текстовых данных. Активно используется в частности в различных системах хранения и управления исходным кодом



Изоощрённые фильтры

- **diff** (и **diff -u**¹⁹) - сравнить 2 файла и получить описание разницы (изменения между ними)
- **patch** - утилита применения изменений от diff
- **sed** - не-интерактивный поточный редактор текста
- **awk** - язык и утилита сканирования и обработки текста

¹⁹Формат **diff -u** : индустриальный стандарт пересылки списка изменений между версиями текстовых данных. Активно используется в частности в различных системах хранения и управления исходным кодом



Изожрённые фильтры

- **diff** (и **diff -u**¹⁹) - сравнить 2 файла и получить описание разницы (изменения между ними)
- **patch** - утилита применения изменений от diff
- **sed** - не-интерактивный поточный редактор текста
- **awk** - язык и утилита сканирования и обработки текста

Упражнение 1: с помощью **diff** получить разницу между своим профайлом `.bashrc` и пользователя ```user```
(`/home/user/.bashrc`)

Упражнение 2: создать файл патча в unified формате, на основе Упражнения 1.

Упражнение 3: создать Unified-патч между домашним каталогом другого пользователя (например `user`) и вашим домашним каталогом. Включить в патч все подкаталоги и файлы.

¹⁹ Формат **diff -u** : индустриальный стандарт пересылки списка изменений между версиями текстовых данных. Активно используется в частности в различных системах хранения и управления исходным кодом



Описываем текст

Как описать текст?

Необходим инструмент и формат описания текста



Описываем текст

Как описать текст?

Необходим инструмент и формат описания текста

Регулярные выражения

Регулярные выражения (regular expression или regexp) - специальные строки символов, которые задаются для поиска совпадающих фрагментов. Иначе говоря это способ описания наборов букв.



Описываем текст

Как описать текст?

Необходим инструмент и формат описания текста

Регулярные выражения

Регулярные выражения (regular expression или regexp) - специальные строки символов, которые задаются для поиска совпадающих фрагментов. Иначе говоря это способ описания наборов букв.

Универсальный язык описания текста

Все Unix-программы, осуществляющие поиск в тексте, используют регулярные выражения.



Элементы регулярных выражений

- **литералы** - обычные символы (буквы и цифры)



Элементы регулярных выражений

- **литералы** - обычные символы (буквы и цифры)
- **метасимволы** - спецсимволы (количество повторов, группировка фрагментов, позиция в тексте).



Элементы регулярных выражений

- **литералы** - обычные символы (буквы и цифры)
- **метасимволы** - спецсимволы (количество повторов, группировка фрагментов, позиция в тексте).

Примеры регулярных выражений:

```
~$ file /bin/*|grep symbolic  
~$ grep -o 'user[0-9]*' /var/log/auth.log
```



Класс на 1 символ

- `.` (точка) - заменяет любой символ

Пример: `「us.r.」` = `'user0'`, `'us rX'`, `'us9r '` и т.д.



Класс на 1 символ

- `.` (точка) - заменяет любой символ
Пример: `us.r.` = 'user0', 'us rX', 'us9r ' и т.д.
- `[]` символьный класс - заменяет любой символ из перечисленных в скобках
 - 1 `user[0-9]` = 'user0', 'user5', но не равно 'user'
 - 2 `-[abc-]` = '--', '-a', '-b', '-c', но не равно '--a'
 - 3 `[^abc]1`²⁰ = 'd1', '11', но не равно 'a1'



Класс на 1 символ

- **.** (точка) - заменяет любой символ
Пример: `「us.r.」` = 'user0', 'us rX', 'us9r ' и т.д.
- **[]** символьный класс - заменяет любой символ из перечисленных в скобках
 - ① `「user[0-9]」` = 'user0', 'user5', но не равно 'user'
 - ② `「-[abc-]」` = '--', '-a', '-b', '-c', но не равно '--a'
 - ③ `「[^abc]1」`²⁰ = 'd1', '11', но не равно 'a1'
- **[:class:]** - дополнительные POSIX-классы для символов, **внутри символьного класса**²¹
Примеры классов: `[:alnum:]`, `[:alpha:]` `[:digit:]` `[:space:]`
`[:lower:]`, `[:upper:]`, `[:print:]`
Примеры regex с POSIX классами: `「[ы[:digit]]」`

Упражнение 1: Из `/var/log/messages` вывести все слова, состоящие из одного символа(любого). Без повторов.

Упражнение 2: То же, что 1, но вывести слова из двух букв.

Упражнение 3: Извлечь все метки времени из `/var/log/messages`



Группировка и квантификаторы - регулируем повторы

Квантификаторы указывают, сколько раз может повторяться символ или выражение, после которого указаны. Не являются шаблонами текста.

Группировка выражений - осуществляется круглыми скобками
«(выражение)»²²

- ?²² - необязательный символ

пример: «a.?b» - совпадёт с 'ab', 'a9b', 'a b'



Группировка и квантификаторы - регулируем повторы

Квантификаторы указывают, сколько раз может повторяться символ или выражение, после которого указаны. Не являются шаблонами текста.

Группировка выражений - осуществляется круглыми скобками
«(выражение)»²²

- **?**²² - необязательный символ

пример: «a.?b» - совпадёт с 'ab', 'a9b', 'a b'

- ***** - любое количество символов, включая нулевое

примеры: «.*», «[[[:digit:]]*»



Группировка и квантификаторы - регулируем повторы

Квантификаторы указывают, сколько раз может повторяться символ или выражение, после которого указаны. Не являются шаблонами текста.

Группировка выражений - осуществляется круглыми скобками
«(выражение)»²²

- **?**²² - необязательный символ
пример: «a.?b» - совпадёт с 'ab', 'a9b', 'a b'
- ***** - любое количество символов, включая нулевое
примеры: «.*», «[:digit:]*»
- **+**²² - не менее одного символа
примеры: «[a-d]+», «(02:)+»

Упражнение 1 - извлечь все слова из 1 или 2 букв из
/var/log/messages

Упражнение 2 - все слова, начинающиеся на a из
/var/log/messages

Упражнение 3 - все цифры из /var/log/messages

